

Trabajo final – XGBoost y SHAP

01-2026

Objetivo del trabajo

Desarrollar y comparar modelos de clasificación para identificar clientes riesgosos en un concesionario, utilizando Regresión Logística y XGBoost, evaluando su desempeño mediante métricas y análisis interpretables basados en SHAP.

Estructura obligatoria del trabajo

El documento debe estar organizado en las siguientes secciones:

- Introducción
- Metodología
- Resultados
- Conclusiones

Toda figura y tabla debe:

- Tener título (numerado)
- Tener fuente (ej: elaboración propia)
- Ser referenciada en el texto antes de aparecer

1. Introducción

La introducción debe presentar:

- Contexto del problema de clasificación de riesgo de clientes.
- Importancia de los modelos predictivos en decisiones financieras y comerciales.
- Explicación breve de los modelos utilizados:
 - Regresión Logística.
 - XGBoost.
- Importancia de la interpretabilidad en Machine Learning.
- Objetivo del trabajo.
- Alcance y estructura del documento.

2. Metodología

La metodología debe explicarse paso a paso de lo realizado.

- Tratamiento de los datos.
- Escalamiento.

- Conjunto de train y test.
- Modelo usado.
- Hiperparámetros a optimizar usando Random Search de sklearn.
- SHAP.
- Validación con 10 muestras.

3. Resultados

3.1 Resultados de la optimización

Presentar:

- Mejores hiperparámetros encontrados.
- Tabla comparativa.
- Discusión del comportamiento de los modelos.
- Explicar qué hiperparámetros favorecieron mayor ajuste o regularización.

3.2 Comparación de modelos

Realizar una discusión profunda entre:

- Regresión Logística.
- XGBoost.

Analizar:

- Capacidad predictiva.
- Sobreajuste.
- Capacidad de generalización.
- Diferencias entre modelos lineales y no lineales.

La selección del mejor modelo debe estar completamente justificada.

3.3 Interpretabilidad con SHAP

Una vez seleccionado el mejor modelo, se debe realizar un análisis profundo utilizando SHAP.

Gráficos obligatorios de SHAP

Importancia global de variables

Incluir:

- SHAP Summary Plot.
- SHAP Bar Plot.

Analizar:

- variables más importantes,

- orden de impacto,
- magnitud de influencia.

Dirección del efecto de las variables

Incluir:

- SHAP Beeswarm Plot.
- SHAP Dependence Plot.

Analizar:

- cómo afectan las variables el riesgo,
- si aumentan o disminuyen la probabilidad,
- relaciones no lineales,
- patrones complejos.

Explicaciones individuales

Incluir:

- SHAP Force Plot.
- Waterfall Plot.

Explicar casos específicos de clientes.

IMPORTANTE

No se acepta únicamente mostrar gráficos.

Cada gráfico debe incluir:

- interpretación técnica,
- análisis crítico,
- discusión profunda,
- relación con el contexto financiero/comercial del concesionario.

3.4 Validación manual del modelo

Con el mejor modelo seleccionado:

Crear 10 clientes ficticios

Deben inventar manualmente:

- valores de todas las variables,
- perfiles distintos de clientes,
- clientes claramente riesgosos y no riesgosos,

- perfiles intermedios o ambiguos.

Clasificación de los 10 clientes

El modelo debe predecir:

- Probabilidad de riesgo.
- Clasificación final.

Análisis obligatorio

Para cada cliente:

- Explicar por qué el modelo lo clasificó así.
- Analizar si existe coherencia lógica.
- Relacionar el resultado con las variables.
- Explicar si el comportamiento del modelo tiene sentido financiero y comercial.

Importante

Las variables de entrada de estos 10 casos deben mostrarse en escala real.

Por esta razón:

- XGBoost NO debe usar variables escaladas.
- La Regresión Logística sí debe usar escalamiento durante entrenamiento.

4. Conclusiones

Las conclusiones deben responder:

- ¿Cuál fue el mejor modelo?
- ¿Por qué?
- ¿Qué variables fueron más importantes?
- ¿Qué aprendieron del análisis SHAP?
- ¿Qué limitaciones tuvo el trabajo?
- ¿Qué mejoras futuras podrían realizarse?

Las conclusiones deben ser técnicas y argumentadas.

Requisitos técnicos

El trabajo debe incluir:

- Código completamente funcional.
- Notebook organizado.
- Comentarios explicativos.

- Resultados reproducibles.

Calidad de gráficos

Los gráficos deben:

- tener alta resolución,
- ser elegantes,
- tener títulos,
- etiquetas claras,
- leyendas legibles,
- interpretación técnica.

No se aceptan gráficos pixelados o sin explicación.

Entregables

1. Documento tipo artículo en PDF.
2. Notebook en Google Colab o Jupyter Notebook.